

## 2.3 理论基础

### 2.3.1 SLAM概率问题建模

SLAM模型由一个运动方程和一个观测方程构成

$$\begin{cases} x_k = f(x_{k-1}, u_k) + w_k \\ z_{k,j} = h(y_j, x_k) + v_{k,j} \end{cases} \quad (2.1)$$

其中 $x_k$ 为相机位姿， $u$ 为运动测量读数， $y_j$ 为路标点， $z_{i,j}$ 为观测到的像素点位置， $w$ ， $v$ 为噪声，两个噪声项满足零均值的高斯分布， $w_k \sim N(0, \mathbf{R}_k)$ ， $v_k \sim N(0, \mathbf{Q}_{k,j})$ ，考虑某个状态 $\mathbf{x}$ ，以及一次与该变量相关的观测 $\mathbf{z}_i$ ，由于噪声的存在，观测服从概率分布 $\mathbf{p}(\mathbf{z}_i|\mathbf{x})$ 。多次观测时，各个测量值相互独立，则多个测量 $\mathbf{r} = (\mathbf{z}_1, \dots, \mathbf{z}_n)^T$ 构建的似然概率为：

$$\mathbf{p}(\mathbf{z}|\mathbf{x}) = \prod_i \mathbf{p}(\mathbf{z}_i|\mathbf{x}) \quad (2.2)$$

如果知道机器人状态的先验信息 $p(x)$ ，如GPS，车轮码盘信息等，则根据Bayes法则，有后验概率：

$$\mathbf{p}(\mathbf{x}|\mathbf{z}) = \frac{\mathbf{p}(\mathbf{z}|\mathbf{x})p(\mathbf{x})}{p(\mathbf{z})} \quad (2.3)$$

求解目标：给定观测的信息，求系统的最优状态，使得在该状态下后验概率最大化，等价于求解状态量 $x$ 的最大似然估计 $\mathbf{p}(\mathbf{x}|\mathbf{z})$ 。通俗地来说就是“在什么样的状态下，最可能产生现在观测到的数据”

$$P(\mathbf{x}|\mathbf{z}) = \frac{P(\mathbf{z}|\mathbf{x})P(\mathbf{x})}{P(\mathbf{z})} \propto P(\mathbf{z}|\mathbf{x})P(\mathbf{x}) \quad (2.4)$$

由此可以得到状态量 $x$ 的最大后验估计

$$\mathbf{x}_{MAP}^* = \arg \max P(\mathbf{x}|\mathbf{z}) = \arg \max P(\mathbf{x}|\mathbf{z})P(\mathbf{x}) \quad (2.5)$$

给定一组观测的信息，可以用最小化负对数的方式求一个高斯分布的最大后验

$$\mathbf{x}_{MAP}^* = \arg \max_x \prod_i p(\mathbf{z}_i | \mathbf{x}) p(\mathbf{x}) \quad (2.6)$$

$$\mathbf{x}_{MAP}^* = \arg \min_x \left[ - \sum_i \ln p(\mathbf{z}_i | \mathbf{x}) - \ln p(\mathbf{x}) \right] \quad (2.7)$$

已知高斯分布

$$P(x) = \frac{1}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp \left( -\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu) \right), x \sim N(\mu, \Sigma) \quad (2.8)$$

两边取负对数

$$-\ln(P(x)) = \frac{1}{2} \ln \left( (2\pi)^N \det(\Sigma) \right) + \frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu) \quad (2.9)$$

等式右边略去与 $x$ 无关的第一项，只要最小化右侧的二次型项，等式2.7代入式2.8后等价于

$$x_{MAP}^* = \arg \min_x \sum_i \frac{1}{2}(z_i - w_i)^T \Sigma_i^{-1}(z_i - w_i) + \frac{1}{2}(x - v_x)^T \Sigma_x^{-1}(x - v_x) \quad (2.10)$$

写成马氏距离（ $\Sigma$  范数）的形式：

$$\mathbf{x}_{\text{MAP}} = \arg \min_{\mathbf{x}} \sum_i \|z_i - w_i\|_{\Sigma_i}^2 + \|\mathbf{x} - v_x\|_{\Sigma_x}^2 \quad (2.11)$$

在仅有视觉传感器的情况下，忽略运动方程，代入SLAM观测方程(2.1)后可得

$$\mathbf{x}^* = \arg \min [\mathbf{z}_{k,j} - h(\mathbf{y}_j, \mathbf{x}_k)]^T \Sigma_{k,j}^{-1} [\mathbf{z}_{k,j} - h(\mathbf{y}_j, \mathbf{x}_k)] \quad (2.12)$$

其中  $\Sigma$  为观测协方差， $\mathbf{z}_{k,j} - h(\mathbf{y}_j, \mathbf{x}_k)$  为观测残差。在实际应用中，通常构建如下的最小二乘问题，通过不断地迭代求解状态量地增量  $\Delta \mathbf{x}$ ，并更新状态： $\mathbf{x} = \mathbf{x}' + \Delta \mathbf{x}$ ，将更新后的状态  $\mathbf{x}$  代入目标函数， $f(\mathbf{x}) = \mathbf{z}_{k,j} - h(\mathbf{y}_j, \mathbf{x}_k)$  即观测残差，使得目标函数的  $\Sigma$  范数达到最小。

$$\Delta \mathbf{x}^* = \arg \min_{\Delta \mathbf{x}} \frac{1}{2} \|\mathbf{f}(\mathbf{x})\|_{\Sigma} \quad (2.13)$$

状态的增量可由高斯-牛顿（Gauss-Newton）法求解，每次迭代需要求解如下的线性方程组

$$\mathbf{J}(\mathbf{x})^T \Sigma^{-1} \mathbf{J}(\mathbf{x}) \Delta \mathbf{x} = -\mathbf{J}(\mathbf{x})^T \Sigma^{-1} \mathbf{f}(\mathbf{x}) \quad (2.14)$$

$\mathbf{J}(\mathbf{x})$  表示目标函数对状态量的雅可比矩阵， $\Sigma^{-1}$  表示状态量的之间的协方差矩阵，方程可简写为  $\mathbf{H} \Delta \mathbf{x} = \mathbf{b}$ ，称为正规方程。

### 2.3.2 Bundle Adjustment

Bundle Adjustment 中文译作光束平差法，是指从视觉重建中提炼出最优的3D模型和相机参数（内参和外参）。从每个特征点反射出来的几束光（Bundles of Light Rays），把相机姿态和特征点的位置做出最优的调整（Adjustment）最后收束到光心的这个过程，简称BA。




图 2-1 Bundle Adjustment 示意图

对于BA，通过2.2.1中提到的概率建模方法，可利用重投影误差构建式（2.14）所示的最小二乘问题：

$$e(\mathbf{X}, \mathbf{T}) = \sum_{i=1}^n \left\| \mathbf{u}_i - \frac{1}{s_i} \mathbf{K} \cdot \mathbf{T} \cdot \mathbf{X}_i \right\|_{\Sigma} \quad (2.15)$$